

Análisis y Clasificación de Gravedad de Siniestros Viales — CABA

Pipeline completo: ingesta → limpieza → integración → EDA → modelado

Materia: Ciencia de Datos (3.4.217) — UADE
Docente: Santiago Gabriel Martín
1er cuatrimestre 2026 · Junio 2026

Datos: 37.849 siniestros viales en CABA (2021-2024), data.buenosaires.gob.ar ·
INDEC Censo 2022 · Meteostat · ArgentinaDatos

1. Resumen ejecutivo

Construimos un pipeline reproducible que clasifica y explica la **gravedad** de un siniestro vial (LEVE vs SEVERO = grave + mortal) y la **cantidad diaria** de siniestros en CABA, sobre 37.849 hechos del período 2021-2024. El proceso evaluó cuantitativamente qué datasets externos aportan señal, descartó con evidencia los que no (clima mensual, flujo vehicular), y los reemplazó por fuentes con la granularidad correcta (clima diario, feriados, agregados de víctimas). El trabajo sigue las etapas del proceso **KDD / CRISP-DM**: selección y limpieza de datos, transformación (feature engineering), minería de datos y evaluación de patrones.

Resultados principales:

- **Modelo final de clasificación:** Random Forest + zona geográfica de k-means como variable sintética — detecta el **72% de los siniestros severos** (recall CV 0,72; ROC-AUC 0,83), el mejor F1-Score de la comparación.
- **El "+35% de siniestros 2021-2024" es en dos tercios un efecto del tránsito:** los vehículos crecieron +22% (peajes) y la tasa por millón de vehículos solo +10% (68 → 75). El tránsito mensual y los siniestros se mueven juntos ($r = 0,88$) — sin normalizar por exposición, la estadística engaña.
- **La lluvia reduce la frecuencia de siniestros (-8%; -21% con lluvia fuerte) pero NO aumenta la gravedad** del siniestro individual — validado por 3 vías independientes.
- **La severidad no es un lugar, es un perfil:** geográficamente es homogénea (4,7-5,6%), pero entre tipos de siniestro varía 6× (peatón mayor 12,9% vs choque vehicular leve 2,0%).
- **El gradiente de velocidad de la vía ordena la severidad de punta a punta:** zona peatonal 20 km/h 3,4% → calle 3,8% → avenida 5,4% → autopista 14,1%.
- **El feriado es el driver más fuerte de la cantidad diaria** (-9,6 siniestros/día), más que cualquier variable climática.

2. Datos y evaluación de integración

Partimos de 6 datasets del portal de datos abiertos de CABA. Antes de integrar, definimos un criterio: un dataset externo se incorpora solo si (a) comparte clave a granularidad útil, (b) aporta señal medible contra el target, y (c) cubre el período de estudio. El veredicto:

Dataset	Veredicto	Evidencia
Hechos (37.849, 2021-24)	BASE	un registro por siniestro, target gravedad
Víctimas (43.255)	INTEGRAR	join 1:1 perfecto por id; hay_peaton es el mejor predictor
Lluvia/temp MENSUAL	DESCARTAR	casi constante por mes; agregarla EMPEORA el CV (-0,009)
Flujo AUSA (radares)	DESCARTAR	36% NaN; solo autopistas; sin 2021 ni mar-sep 2022
Flujo Anillo Digital	DESCARTAR	74% NaN (termina feb 2022); 6-9 sensores
Clima DIARIO (Meteostat)	AGREGAR	1461/1461 días; variación real entre siniestros
Feriados (ArgentinaDatos)	AGREGAR	driver #1 de la cantidad diaria
Población (Censo 2022)	AGREGAR	tasas por habitante por comuna
Seguridad Vial AUSA	VALIDACIÓN	superficie seca/mojada por incidente (no mergeable)
Peajes autopistas (IDECBA)	AGREGAR	único conteo vehicular continuo: normaliza por exposición
Sensores de volumen (2024)	AGREGAR	95 puntos en avenidas: normaliza el ranking de arterias

La decisión metodológica clave fue probar que **el clima mensual y el flujo vehicular no aportan**: sus valores son casi constantes dentro de cada mes (redundantes con la estación) y el join espacial del flujo solo sería válido para el 6% de los siniestros. Documentar este resultado negativo con números es parte del valor del trabajo.

3. Análisis exploratorio


3.1 Panorama general: cuántos, cuándo, quiénes

37.849 siniestros en 2021-2024 (25,9 por día), 5,7% severos. La hora pico de siniestros sigue la hora pico de tránsito; la víctima más frecuente es por lejos la **moto**, seguida del peatón, y la contraparte más frecuente es el auto.




Panorama: siniestros por año, por hora del día, víctima y contraparte más frecuentes.


3.2 Evolución temporal y tasas por comuna



Crecimiento sostenido post-pandemia: +35,2% entre 2021 (7.819) y 2024 (10.569).




Tasa anual de siniestros cada 100.000 habitantes (Censo 2022). Máximo: Comuna 1 (458,5); mínimo: Comuna 6 (195,4) — 2,3× de diferencia.



Top 10 arterias por cantidad de siniestros. Concentración, no riesgo por vehículo: sin datos de flujo no se puede normalizar por exposición.


3.3 ¿Más siniestros porque hay más tránsito? Sí, en dos tercios

Los siniestros crecieron +35% entre 2021 y 2024. ¿Empeoró la seguridad vial o solo volvió el tránsito post-pandemia? Con el único conteo vehicular continuo de la Ciudad (peajes de autopistas, IDECBA) como proxy de exposición: el tránsito mensual y los siniestros mensuales se mueven juntos ($r = 0,88$), el tránsito creció +22% y la tasa de siniestros por millón de vehículos solo +10% (68 → 75). Es decir: **dos tercios del aumento es exposición** (más autos en la calle), un tercio es deterioro real. Con los peajes, además, la tasa por autopista: el corredor oeste (25 de Mayo + Perito Moreno, 0,55 siniestros por millón de vehículos) duplica a la Illia (0,10). Y con los sensores de volumen 2024 (95 puntos), el ranking de arterias normalizado: parte de las "avenidas peligrosas" simplemente llevan más tránsito.



lqz: tránsito (peajes) y siniestros mensuales 2021-2024 se mueven juntos. Der: cada punto es un mes — la relación es lineal y estable entre años.


El ranking cambia cuando se controla por tránsito



El ranking de arterias cambia al normalizar por tránsito (sensores 2024, punto medido). Índice comparativo: el sensor mide un punto, no toda la extensión de la arteria.


3.4 ¿Los días de lluvia tienen más siniestros? No: tienen menos

Los días con lluvia registran **-8% de siniestros** (24,5 vs 26,6 por día) y el efecto es dosis-dependiente: con más de 20 mm caen **-21%**. La composición de víctimas casi no cambia (es una reducción general de exposición: circula menos gente) y la gravedad del siniestro individual tampoco (5,7% vs 5,9% SEVERO). El resultado se sostiene en **tres granularidades y tres fuentes**: a nivel diario (Meteostat), a nivel **horario** — ¿llovía en el momento exacto del siniestro? (Open-Meteo: frecuencia -4,9%, gravedad sin diferencia) — y en los registros per-incidente de AUSA, donde la superficie MOJADA muestra **menos** lesividad que la SECA (27,8% vs 39,1% con víctimas).



Izq: siniestros/día por intensidad de lluvia. Der: dispersión precipitación vs cantidad diaria.


3.5 Combinaciones de variables



Los cruces dicen más que las variables aisladas: madrugada de finde concentra severidad y jóvenes; la lluvia baja la frecuencia en todos los tipos de vía; la banda crítica de severidad es 65+.

3.6 El gradiente velocidad → severidad


No existe dataset público de velocidad medida; en CABA el límite legal lo fija el tipo de vía. Sumando las áreas de prioridad peatonal (20 km/h) el gradiente queda completo y monotónico — la mejor evidencia disponible del mecanismo velocidad → gravedad:



Zona 20 km/h: 3,4% · Calle (40): 3,8% · Avenida (60): 5,4% · Autopista (80+): 14,1% SEVERO.

3.7 Edad × fin de semana

Los jóvenes (18-29) pasan del 28,8% de las víctimas entre semana al **33,5% el fin de semana**. En la madrugada de finde la mediana baja a 31 años y el 43,9% de los siniestros tiene víctimas menores de 30. El perfil de riesgo completo: **jóvenes + madrugada + finde = 2× frecuencia y 2× severidad**. Matiz importante: la severidad individual por edad la dominan los mayores de 65 (12% SEVERO — fragilidad), no los jóvenes (7,2%, promedio). Exposición y vulnerabilidad son mecanismos distintos.



Composición etaria semana vs finde, y % de siniestros con víctimas jóvenes por franja horaria.



4. Modelado

4.1 Clasificación de gravedad (Árbol de Decisión, Random Forest, Regresión Logística)

Problema de **aprendizaje supervisado — clasificación**. El target original (LEVE 94% / GRAVE 4,6% / MORTAL 1,1%) es inviable con 3 clases; lo reagrupamos en LEVE vs SEVERO. Con un dataset tan desbalanceado la *accuracy* engaña (predecir siempre LEVE "acierta" el 94%), así que evaluamos con matriz de confusión, precision, recall, F1-Score y ROC-AUC, ponderando las clases con `class_weight=balanced`. Comparación bajo el mismo protocolo (validación cruzada estratificada de 5 particiones):


Modelo	Accuracy	Precision SEV.	Recall SEV.	F1 SEV.	ROC-AUC
Árbol de decisión d=4 (interpretable)	0,486	0,094	0,92	0,171	0,761
Árbol de decisión d=7	0,602	0,110	0,83	0,194	0,787
Regresión Logística	0,712	0,136	0,75	0,230	0,814
Random Forest (n=300, d=10)	0,753	0,151	0,72	0,250	0,828
RF + zona k-means (FINAL)	0,763	0,157	0,72	0,257	0,833

Los árboles usan el **índice de Gini** como criterio de impureza, con profundidad y hojas mínimas limitadas como **poda preventiva** contra el sobreajuste. La mejora final viene de combinar **técnicas**: la zona geográfica de k-means se ajusta dentro de cada fold de validación y se usa como **variable sintética** del Random Forest. El árbol de profundidad 4 se conserva como modelo interpretable de screening (recall 0,92: detecta casi todos los severos, a costa de falsos positivos).



Modelo final Random Forest + zona: matriz de confusión y curva ROC (test 20%, recall SEVERO 0,73).


Árbol de Decisión (Gini, profundidad limitada como poda preventiva contra el sobreajuste)



Árbol de Decisión interpretable (criterio Gini, primeros 3 niveles): reglas si-entonces legibles.

4.2 Regresión: cantidad diaria de siniestros


Problema de **regresión** (target numérico), evaluado con MSE, RMSE, MAE y R^2 . Validación con split temporal honesto: entrenamiento 2021-2023, test 2024 (un año nunca visto). Gana la **Regresión Lineal Múltiple con dummies** (RMSE 7,43 · MAE 5,84 · R^2 0,385) sobre el Árbol de Regresión (R^2 0,241) y Random Forest (R^2 0,313) — los árboles no extrapolan la tendencia creciente. Y un paso más de interpretación: reemplazar la feature abstracta `tendencia` por el **tránsito real del mes** (peajes) mejora el modelo a **R^2 0,397** — la "tendencia creciente" queda explicada por su mecanismo, la recuperación del tránsito. Coeficientes interpretables: **feriado -9,6 siniestros/día** (el efecto más fuerte), fin de semana -5,3, día de lluvia -1,7 (-0,036 por mm), tendencia +2,9/año.



Predicción vs real sobre 2024 (media móvil 7 días): el modelo lineal captura tendencia y estacionalidad semanal.

4.3 Aprendizaje no supervisado

K-means de perfiles ($k=5$, elegido con el método del codo): la severidad varía 6× entre tipos de siniestro — peatón mayor (73 años, 12,9% SEVERO) > peatón adulto (36 años, 10,3%) > moto laboral (32 años, 7,0%) > finde joven (36 años, 6,3%) > vehicular leve (32 años, 2,0%). En contraste, el k-means geográfico muestra severidad casi pareja entre zonas (spread 0,9 pp): **el riesgo de gravedad no es un lugar, es un tipo de siniestro**.



5. Conclusiones

- ## Limitaciones

- **Sesgo de registro (detectado y medido):** los siniestros graves se documentan completos, muchos leves quedan con placeholders — la edad falta en el 33% de los LEVE pero en menos del 2% de los GRAVE/MORTAL, y "víctima desconocida" es LEVE el 99,8% de las veces. El modelo aprovecha en parte ese atajo. Chequeo de robustez sobre el 57% de casos con datos completos (tasa SEVERO 9,9%): ROC-AUC 0,74 (vs 0,83 global), recall 0,52, F1 0,33 — el poder discriminante real, declarado.
- La precisión sobre SEVERO es baja (~0,16): el modelo detecta el 73% de los severos pero con falsos positivos — útil como screening, no como predictor puntual. La severidad depende de física del impacto (velocidad real, ángulo) que ningún dataset público captura.

- Las features víctima/acusado se conocen *después* del hecho: el modelo explica factores de riesgo y screening post-siniestro, no predice antes de que ocurra.
- No existe dataset público de alcoholemia ni de velocidades medidas, dos variables presumiblemente relevantes.

Reproducibilidad

Todo el trabajo es reproducible: notebook de 80 celdas que corre de punta a punta, datasets externos descargados como archivos estáticos (sin llamadas a APIs en tiempo de ejecución), semillas fijas (random_state=42) y protocolo de validación único. Artefactos: dataset integrado, 23 gráficos, 4 mapas interactivos y 4 modelos serializados. Todas las técnicas aplicadas corresponden al programa de la materia: EDA (Clase 4), Árboles de Decisión (Clase 7), Random Forest y validación de modelos (Clase 8), regresión (Clase 9) y aprendizaje no supervisado (Clase 10).