

Análisis y Clasificación de Gravedad de Siniestros Viales — CABA

Pipeline completo: ingesta → limpieza → integración → EDA → modelado

Materia: Ciencia de Datos (3.4.217) — UADE
Docente: Santiago Gabriel Martín
1er cuatrimestre 2026 · Junio 2026

Datos: 37.849 siniestros viales en CABA (2021-2024), data.buenosaires.gob.ar ·
INDEC Censo 2022 · Meteostat · ArgentinaDatos

1. Resumen ejecutivo

Construimos un pipeline reproducible que clasifica y explica la **gravedad** de un siniestro vial (LEVE vs SEVERO = grave + mortal) y la **cantidad diaria** de siniestros en CABA, sobre 37.849 hechos del período 2021-2024. El proceso evaluó cuantitativamente qué datasets externos aportan señal, descartó con evidencia los que no (clima mensual, flujo vehicular), y los reemplazó por fuentes con la granularidad correcta (clima diario, feriados, agregados de víctimas). El trabajo sigue las etapas del proceso **KDD / CRISP-DM**: selección y limpieza de datos, transformación (feature engineering), minería de datos y evaluación de patrones.

Resultados principales:

- **Modelo final de clasificación:** Random Forest (excluyendo los flags de registro *_DESCONOCIDO, que son leakage de proceso) — detecta el **67% de los siniestros severos** en el test holdout (recall 0,67; ROC-AUC 0,81), el mejor F1-Score de la comparación.
- **El "+35% de siniestros 2021-2024" es en dos tercios un efecto del tránsito:** los vehículos crecieron +22% (peajes) y la tasa por millón de vehículos solo +10% (68 → 75). El tránsito mensual y los siniestros se mueven juntos ($r = 0,88$) — sin normalizar por exposición, la estadística engaña.
- **La lluvia reduce la frecuencia de siniestros (-8%; -21% con lluvia fuerte) pero NO aumenta la gravedad** del siniestro individual — validado por 3 vías independientes.
- **La severidad no es un lugar, es un perfil:** geográficamente es homogénea (4,7-5,6%), pero entre tipos de siniestro varía 6× (peatón mayor 12,9% vs choque vehicular leve 2,0%).
- **El gradiente de velocidad de la vía ordena la severidad de punta a punta:** zona peatonal 20 km/h 3,4% → calle 3,8% → avenida 5,4% → autopista 14,1%.
- **El feriado es el driver más fuerte de la cantidad diaria** (-9,6 siniestros/día), más que cualquier variable climática.

2. Datos y evaluación de integración

Partimos de 6 datasets del portal de datos abiertos de CABA. Antes de integrar, definimos un criterio: un dataset externo se incorpora solo si (a) comparte clave a granularidad útil, (b) aporta señal medible contra el target, y (c) cubre el período de estudio. El veredicto:


Dataset	Veredicto	Evidencia
Hechos (37.849, 2021-24)	BASE	un registro por siniestro, target gravedad
Víctimas (42.650)	INTEGRAR	join 1:1 perfecto por id; hay_peaton es el mejor predictor
Lluvia/temp MENSUAL	DESCARTAR	casi constante por mes: un solo valor para todos los siniestros del mes
Flujo AUSA (radares)	DESCARTAR	36% NaN; solo autopistas; sin 2021 ni mar-sep 2022
Flujo Anillo Digital	DESCARTAR	74% NaN (termina feb 2022); 6-9 sensores
Clima DIARIO (Meteostat)	AGREGAR	1461/1461 días; variación real entre siniestros
Feriados (ArgentinaDatos)	AGREGAR	driver #1 de la cantidad diaria
Población (Censo 2022)	AGREGAR	tasas por habitante por comuna
Seguridad Vial AUSA	VALIDACIÓN	superficie seca/mojada por incidente (no mergeable)
Peajes autopistas (IDECBA)	AGREGAR	único conteo vehicular continuo: normaliza por exposición
Sensores de volumen (2024)	AGREGAR	95 puntos en avenidas: normaliza el ranking de arterias

La decisión metodológica clave fue probar que **el clima mensual y el flujo vehicular no aportan**: sus valores son casi constantes dentro de cada mes (redundantes con la estación) y el join espacial del flujo solo sería válido para el 6% de los siniestros. Documentar este resultado negativo con números es parte del valor del trabajo.

3. Análisis exploratorio


3.1 Panorama general: cuántos, cuándo, quiénes

37.849 siniestros en 2021-2024 (25,9 por día), 5,7% severos. La hora pico de siniestros sigue la hora pico de tránsito; la víctima más frecuente es por lejos la **moto**, seguida del peatón, y la contraparte más frecuente es el auto.




Panorama: siniestros por año, por hora del día, víctima y contraparte más frecuentes.

3.2 Evolución temporal y tasas por comuna



Crecimiento sostenido post-pandemia: +35,2% entre 2021 (7.819) y 2024 (10.569).




Tasa anual de siniestros cada 100.000 habitantes (Censo 2022). Máximo: Comuna 1 (458,5); mínimo: Comuna 6 (195,4) — 2,3× de diferencia.



Top 10 arterias por cantidad de siniestros. Concentración, no riesgo por vehículo: sin datos de flujo no se puede normalizar por exposición.

3.3 ¿Más siniestros porque hay más tránsito? Sí, en dos tercios

Los siniestros crecieron +35% entre 2021 y 2024. ¿Empeoró la seguridad vial o solo volvió el tránsito post-pandemia? Con el único conteo vehicular continuo de la Ciudad (peajes de autopistas, IDECBA) como proxy de exposición: el tránsito mensual y los siniestros mensuales se mueven juntos ($r = 0,88$), el tránsito creció +22% y la tasa de siniestros por millón de vehículos solo +10% (68 → 75). Es decir: **dos tercios del aumento es exposición** (más autos en la calle), un tercio es deterioro real. Con los peajes, además, la tasa por autopista: el corredor oeste (25 de Mayo + Perito Moreno, 0,55 siniestros por millón de vehículos) quintuplica a la Illia (0,10). Y con los sensores de volumen 2024 (95 puntos), el ranking de arterias normalizado: parte de las "avenidas peligrosas" simplemente llevan más tránsito.




lqz: tránsito (peajes) y siniestros mensuales 2021-2024 se mueven juntos. Der: cada punto es un mes — la relación es lineal y estable entre años.



El ranking de arterias cambia al normalizar por tránsito (sensores 2024, punto medido). Índice comparativo: el sensor mide un punto, no toda la extensión de la arteria.


3.4 ¿Los días de lluvia tienen más siniestros? No: tienen menos

Los días con lluvia registran **-8% de siniestros** (24,5 vs 26,6 por día) y el efecto es dosis-dependiente: con más de 20 mm caen **-21%**. La composición de víctimas casi no cambia (es una reducción general de exposición: circula menos gente) y la gravedad del siniestro individual tampoco (5,7% vs 5,9% SEVERO). El resultado se sostiene en **tres granularidades y tres fuentes**: a nivel diario (Meteostat), a nivel **horario** — ¿llovía en el momento exacto del siniestro? (Open-Meteo: frecuencia -4,9%, gravedad sin diferencia) — y en los registros per-incidente de AUSA, donde la superficie MOJADA muestra **menos** lesividad que la SECA (27,8% vs 39,1% con víctimas).




Izq: siniestros/día por intensidad de lluvia. Der: dispersión precipitación vs cantidad diaria.

3.5 Combinaciones de variables




El CUÁNDO: la madrugada de fin de semana concentra la severidad (12,1% vs 5,5%); la noche domina y la lluvia nocturna suma poco (+0,6 pp).



El QUIÉN y la VÍA: la lluvia baja la frecuencia en todos los tipos de vía (no castiga más a las autopistas); la banda crítica de severidad es 65+ (fragilidad), no los jóvenes.

3.6 El gradiente velocidad → severidad


No existe dataset público de velocidad medida; en CABA el límite legal lo fija el tipo de vía. Sumando las áreas de prioridad peatonal (20 km/h) el gradiente queda completo y monotónico — la mejor evidencia disponible del mecanismo velocidad → gravedad:



Zona 20 km/h: 3,4% · Calle (40): 3,8% · Avenida (60): 5,4% · Autopista (80+): 14,1% SEVERO.

3.7 Edad × fin de semana

Los jóvenes (18-29) pasan del 28,8% de las víctimas entre semana al **33,4% el fin de semana**. En la madrugada de finde la mediana baja a 31 años y el 43,9% de los siniestros tiene víctimas menores de 30. El perfil de riesgo completo: **jóvenes + madrugada + finde = 2× frecuencia y 2× severidad**. Matiz importante: la severidad individual por edad la dominan los mayores de 65 (12% SEVERO — fragilidad), no los jóvenes (7,2%, promedio). Exposición y vulnerabilidad son mecanismos distintos.



Composición etaria semana vs finde, y % de siniestros con víctimas jóvenes por franja horaria.


4. Modelado

4.1 Clasificación de gravedad (Árbol de Decisión, Random Forest, Regresión Logística)


Problema de **aprendizaje supervisado — clasificación**. El target original (LEVE 94% / GRAVE 4,6% / MORTAL 1,1%) es inviable con 3 clases; lo reagrupamos en LEVE vs SEVERO. Con un dataset tan desbalanceado la *accuracy* engaña (predecir siempre LEVE "acierta" el 94%), así que evaluamos con matriz de confusión, precision, recall, F1-Score y ROC-AUC, ponderando las clases con `class_weight=balanced`. Protocolo: el test holdout (20%, estratificado) se separa primero y queda intacto; la comparación de modelos corre por validación cruzada estratificada de 5 particiones solo sobre el train:

Modelo	Accuracy	Precision SEV.	Recall SEV.	F1 SEV.	ROC-AUC
Árbol de decisión d=4 (interpretable)	0,626	0,111	0,79	0,194	0,756
Árbol de decisión d=7	0,690	0,125	0,73	0,214	0,768
Regresión Logística	0,715	0,137	0,75	0,231	0,815
Random Forest (n=300, d=10) (FINAL)	0,778	0,157	0,65	0,253	0,811
RF + zona k-means (ablación)	0,794	0,166	0,64	0,264	0,816

Los árboles usan el **índice de Gini** como criterio de impureza, con profundidad y hojas mínimas limitadas como **poda preventiva** contra el sobreajuste. Probamos sumar la zona geográfica de k-means como **variable sintética** (se ajusta dentro de cada fold de validación para no filtrar información), pero aporta apenas +0,005 de ROC-AUC — dentro del ruido —, así que el modelo final es el Random Forest sin ella. El árbol de profundidad 4 se conserva como modelo interpretable de screening (recall 0,79: detecta la mayoría de los severos, a costa de falsos positivos).




Modelo final Random Forest (sin flags de registro): matriz de confusión y curva ROC (test 20%, recall SEVERO 0,67).




Importancia de variables del modelo final: dominan la edad media, el % masculino y los agregados de víctimas (peatón, moto). Excluimos las categorías DESCONOCIDO (sesgo de registro — causalidad inversa gravedad→completitud), declarado en Limitaciones.

Calibración del umbral (caso de uso: triage de gravedad). El recall reportado (0,67) es el del umbral por defecto (0,50); el umbral es una **decisión**, no una propiedad del modelo. Para priorizar la respuesta al registrar un siniestro, perder un caso severo cuesta más que una falsa alarma, así que conviene **bajar el umbral**: a 0,36 el recall sube a **0,85** (marca como severo el 42% de los casos, vs 26% por defecto), a costa de precisión. No se cambia de modelo —el Random Forest discrimina mejor que el árbol en todo punto de operación (a igual precisión 0,11, el RF da recall 0,85 vs 0,79 del árbol)— se elige su punto sobre la curva precisión-recall.




Curva precisión-recall del modelo final: el umbral por defecto (0,50) y el umbral de triage (0,36) son dos puntos de operación del mismo modelo, según el costo de perder un severo.



Árbol de Decisión interpretable (criterio Gini, primeros 3 niveles): reglas si-entonces legibles.

4.2 Regresión: cantidad diaria de siniestros


Problema de **regresión**: predecir cuántos siniestros habrá en un día dado de CABA. Los inputs: calendario (día de semana, mes, feriado, finde — conocido de antemano), clima (pronóstico de lluvia y temperatura) y tránsito del mes (contemporáneo: el total mensual se conoce al cerrar el mes; en un uso operativo se usaría el mes anterior o una proyección — acá su rol es explicativo). Uso práctico: dimensionar recursos (guardias del SAME, operativos de tránsito): "feriado con lluvia → ~15 siniestros esperados, no los ~26 de un día típico". Evaluado con MSE, RMSE, MAE y R^2 . Validación con split temporal honesto: entrenamiento 2021-2023, test 2024 (un año nunca visto). Gana la **Regresión Lineal Múltiple con dummies** (RMSE 7,43 · MAE 5,84 · R^2 0,385) sobre el Árbol de Regresión (R^2 0,241) y Random Forest (R^2 0,313) — los árboles no extrapolan la tendencia creciente. Y un paso más de interpretación: reemplazar la feature abstracta "tendencia" por el **tránsito real del mes** (peajes) mejora el modelo a **R^2 0,397** — la "tendencia creciente" queda explicada por su mecanismo, la recuperación del tránsito. Coeficientes interpretables: **feriado -9,6 siniestros/día** (el efecto más fuerte), fin de semana -5,3, día de lluvia -1,7 (-0,036 por mm), tendencia +2,9/año.



Predicción vs real sobre 2024 (media móvil 7 días): el modelo lineal captura tendencia y estacionalidad semanal.


4.3 Aprendizaje no supervisado

K-means de perfiles (k=5, elegido con el método del codo): la severidad varía 6× entre tipos de siniestro — peatón mayor (73 años, 12,9% SEVERO) > peatón adulto (10,3%) > moto laboral (7,0%) > finde joven (6,3%) > vehicular leve (2,0%). En contraste, el k-means geográfico muestra severidad casi pareja entre zonas (spread 0,9 pp): **el riesgo de gravedad no es un lugar, es un tipo de siniestro**.



% SEVERO por perfil de siniestro (k-means k=5) vs promedio global.

DBSCAN (eps=60 m) encuentra 29 micro-hotspots que concentran el 4,6% de los siniestros — el "top de esquinas peligrosas": el mayor acumula 153 siniestros en un solo punto (accesos de Av. Gral. Paz, Comuna 12) y uno combina 76 siniestros con 11,8% de severidad. **PCA**: se necesitan 7 de 8 componentes para el 80% de la varianza — las features son casi ortogonales y no conviene reducir dimensionalidad. **Apriori**: las reglas hacia SEVERO cuantifican los factores de riesgo: PEATÓN $\times 2,1$ ($\times 2,2$ en avenida), MADRUGADA $\times 2,2$, MOTO $\times 1,4$, FINDE $\times 1,3$.



Micro-hotspots DBSCAN (rojo = severidad sobre el promedio; tamaño = cantidad de siniestros).

5. Conclusiones

1. La señal de gravedad está en el *quién* y el *cuándo* (peatón, moto, mayores de 65, madrugada de finde, tipo de vía) — no en el contexto ambiental ni en el lugar exacto.
2. El crecimiento de siniestros es ante todo *exposición*: dos tercios del +35% lo explica el tránsito (+22%); la tasa por vehículo subió +10%. La regresión lo confirma: el tránsito mensual reemplaza y supera a la tendencia abstracta.
3. La lluvia es un factor de *frecuencia* (menos exposición → menos siniestros), no de *gravedad*. Confirmado por el clasificador, el EDA diario y los registros per-incidente de AUSA.
4. La velocidad de la vía es el factor estructural de severidad más claro: el gradiente 20→40→60→80+ km/h multiplica por 4 el porcentaje de siniestros severos.
5. Para política pública: proteger peatones en avenidas, controles en madrugadas de fin de semana, atención a mayores de 65, e intervenciones puntuales en los hotspots identificados.
6. Metodológicamente: evaluar la integración *antes* de integrarla evitó arrastrar ruido; reagrupar el target fue la mejora más barata; y combinar técnicas (la zona de k-means como variable sintética del Random Forest) dio el mejor modelo de la comparación.

Limitaciones

- **Sesgo de registro (detectado y medido)**: los siniestros graves se documentan completos, muchos leves quedan con placeholders — la edad falta en el 33% de los LEVE pero en menos del 2% de los GRAVE/MORTAL, y "víctima desconocida" es LEVE el 99,8% de las veces — marcar que falta un dato es consecuencia de la gravedad (causalidad inversa). Por eso **excluimos los flags *_DESCONOCIDO del modelo final**: sacarlos cuesta solo -0,015 de ROC-AUC, prueba de que el modelo no vivía del atajo. Y como piso honesto, el chequeo de robustez sobre el 57% de casos con datos completos (tasa SEVERO 9,9%) da ROC-AUC 0,73 (vs 0,81 global), recall 0,51, F1 0,32 — el poder discriminante real, declarado.

- La precisión sobre SEVERO es baja ($\sim 0,16$): el modelo detecta el 67% de los severos pero con falsos positivos — útil como screening, no como predictor puntual. La severidad depende de física del impacto (velocidad real, ángulo) que ningún dataset público captura.
- Las features víctima/acusado se conocen *después* del hecho: el modelo explica factores de riesgo y screening post-siniestro, no predice antes de que ocurra.
- No existe dataset público de alcoholemia ni de velocidades medidas, dos variables presumiblemente relevantes.

Reproducibilidad

Todo el trabajo es reproducible: un notebook que corre de punta a punta, datasets externos descargados como archivos estáticos (sin llamadas a APIs en tiempo de ejecución), semillas fijas (`random_state=42`) y protocolo de validación único. Artefactos: dataset integrado, 25 gráficos, 4 mapas interactivos y 4 modelos serializados. Todas las técnicas aplicadas corresponden al programa de la materia: EDA (Clase 4), Árboles de Decisión (Clase 7), Random Forest y validación de modelos (Clase 8), regresión (Clase 9) y aprendizaje no supervisado (Clase 10).